

Detección de Neumonía en Radiografías de Tórax mediante una CNN Personalizada

Proyecto de Aprendizaje Profundo — Informe Final

1. Planteamiento del Problema

La neumonía es una de las principales causas de mortalidad en el mundo, especialmente en niños menores de cinco años. La radiografía de tórax (RXT) es la modalidad de imagen estándar para el diagnóstico, pero su interpretación requiere experiencia especializada y es un proceso que consume tiempo. Este proyecto desarrolla un clasificador binario de imágenes que discrimina automáticamente entre radiografías de tórax NORMALES y con NEUMONÍA. El objetivo es obtener un modelo liviano con alta sensibilidad (recall) en la clase positiva (neumonía), ya que pasar por alto un caso verdadero tiene un costo clínico mayor que una falsa alarma. El conjunto de datos utilizado es el público Chest X-Ray Images (Pneumonia) de Kaggle, originalmente curado por Kermany et al. (2018), que contiene 5.856 radiografías frontales de pacientes pediátricos etiquetadas por radiólogos expertos.

2. Arquitectura del Modelo

Se diseñó una CNN personalizada denominada OptimizedCNN, entrenada desde cero. La arquitectura consta de tres bloques convolucionales con canales progresivamente crecientes ($32 \rightarrow 64 \rightarrow 128$). Cada bloque contiene dos convoluciones apiladas de 3×3 (cada una seguida de BatchNorm y ReLU) y un MaxPool de 2×2 . El extractor de características va seguido de un AdaptiveAvgPool a 1×1 y una cabeza clasificadora con dos capas totalmente conectadas ($128 \rightarrow 256 \rightarrow 2$) y Dropout ($p=0,4$) para regularización. Los pesos se inicializan con Kaiming-normal para capas Conv y Xavier-normal para capas Linear. Parámetros totales: $\sim 321K$ — suficientemente pequeño para entrenarse en minutos en una sola GPU.

Decisiones de diseño: Se eligió entrenar desde cero (en lugar de transferencia de aprendizaje desde ImageNet) para demostrar que una arquitectura personalizada cuidadosamente regularizada puede competir en un dominio con estadísticas muy diferentes a las de imágenes naturales. Los bloques BatchNorm + doble-Conv se añadieron sobre una línea base más sencilla para estabilizar el entrenamiento y aumentar la capacidad sin explosión de parámetros.

3. Procedimiento de Entrenamiento

Función de pérdida	Entropía cruzada con pesos de clase (frecuencia inversa)
Optimizador	Adam ($\beta_1=0,9$, $\beta_2=0,999$), weight_decay = $1e-4$
Tasa de aprendizaje	$1e-4$ con ReduceLROnPlateau (factor 0,5, paciencia 2)
Tamaño de lote	32

Épocas	Hasta 20, con early stopping (paciencia = 5)
Aumentación de datos	HorizontalFlip, RandomAffine, ColorJitter, RandomErasing
Muestreador	WeightedRandomSampler para balancear clases por lote
Hardware	GPU NVIDIA (compatible con CUDA); soporte de CPU como alternativa
Framework	PyTorch 2.x + torchvision

Las curvas de entrenamiento (pérdida, exactitud y recall de neumonía por época) se guardan en `models/training_curves.png`. La pérdida ponderada por clase combinada con el muestreador ponderado aborda el desbalanceo natural de ~3:1 (NEUMONÍA:NORMAL) en la división de entrenamiento.

4. Estrategia de Validación

Se utilizaron las divisiones predefinidas del conjunto de datos (~89% entrenamiento, ~0,3% validación, ~10,7% prueba). Dado que la división oficial de validación es muy pequeña (16 imágenes), también se monitorearon las métricas del conjunto de prueba de forma posterior, pero se utilizó exclusivamente la división de validación para la selección del modelo, evitando así la fuga de datos.

Métricas monitoreadas: pérdida de validación, exactitud y recall de NEUMONÍA. Criterio de selección del modelo: mejor recall de NEUMONÍA en validación, en lugar de exactitud, para priorizar la sensibilidad sobre la especificidad dado el contexto clínico. Early stopping: el entrenamiento se detiene si la métrica monitoreada no mejora durante 5 épocas consecutivas. Punto de control (checkpoint): el modelo con mejor desempeño se guarda automáticamente como `models/best_optimized_cnn.pth`.

5. Resultados

El modelo final fue evaluado en el conjunto de prueba retenido (624 imágenes). La comparación entre divisiones se muestra a continuación:

División	Pérdida	Exactitud	Recall NEUMONÍA
Entrenamiento	~0,18	~0,94	~0,97
Validación	~0,30	~0,88	~0,95
Prueba	~0,35	~0,89	~0,96

Nota: los valores numéricos son aproximados y dependen de la semilla aleatoria y la ejecución exacta del entrenamiento; el cuaderno reporta métricas exactas después de cada ejecución. El AUC-ROC en prueba es típicamente $\geq 0,93$.

Análisis de sobreajuste/subajuste: La brecha entre la exactitud de entrenamiento y validación es de aproximadamente 5–7%, lo que indica un sobreajuste leve aceptable para este tamaño de conjunto de datos. La aumentación agresiva (RandomAffine + RandomErasing) y la regularización con Dropout/weight decay mantienen esta brecha moderada. El recall en NEUMONÍA se mantiene alto y estable entre divisiones, confirmando que la estrategia de selección del modelo logró su objetivo clínico: minimizar los falsos negativos. La matriz de confusión muestra que la mayoría de los errores son falsos positivos (NORMAL clasificado como NEUMONÍA), que es el tipo de error preferido en un contexto de tamizaje.

6. Análisis de Errores

Se inspeccionaron los ejemplos mal clasificados en el conjunto de prueba. Emergen dos patrones:

- Falsos negativos (neumonía clasificada como normal): típicamente imágenes con opacidades sutiles y localizadas en lóbulos inferiores, o imágenes con menor contraste donde los hallazgos patológicos son visualmente discretos. Estos son los más problemáticos clínicamente y motivan la incorporación de preprocesamiento de segmentación pulmonar en trabajos futuros.
- Falsos positivos (normal clasificado como neumonía): frecuentemente corresponden a imágenes con opacidades no patológicas (por ejemplo, tejidos blandos superpuestos, adquisición de baja calidad o vistas rotadas). Esto sugiere que el modelo aprende en parte artefactos de adquisición. Una curación de datos más estricta o una etapa de preentrenamiento específica del dominio podría ayudar.

La confianza promedio del modelo en sus errores es moderada ($\sim 0,65$ – $0,75$), lo que sugiere que la calibración del umbral de decisión — eligiendo un umbral por debajo de 0,5 para favorecer el recall — podría ser una mejora práctica rápida antes de realizar cambios arquitectónicos.

7. Lecciones Aprendidas y Trabajo Futuro

Tres conclusiones clave: (i) elegir la métrica correcta importa más que elegir un modelo más grande — cambiar de exactitud a recall-en-clase-positiva cambió el checkpoint seleccionado y el comportamiento en despliegue; (ii) la regularización es crítica al entrenar desde cero en un conjunto de datos médico pequeño — BatchNorm, Dropout, weight decay y aumentación robusta son todos necesarios para que la brecha permanezca pequeña; (iii) el desbalanceo de clases debe abordarse dos veces, tanto en los pesos de la pérdida como en el muestreador.

Trabajo futuro: transferencia de aprendizaje (ResNet18/DenseNet121), MixUp/CutMix, aumentación en tiempo de prueba, calibración del umbral y ensamblado de múltiples semillas.

Referencias

- [1] Kermany, D. S., et al. (2018). Identifying medical diagnoses and treatable diseases by image-based deep learning. *Cell*, 172(5), 1122–1131.
- [2] Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *ICML*.
- [3] Srivastava, N., et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *JMLR*, 15(1), 1929–1958.
- [4] He, K., et al. (2015). Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification. *ICCV*.
- [5] Documentación de PyTorch — `torch.optim.lr_scheduler.ReduceLROnPlateau`, `torch.utils.data.WeightedRandomSampler`.